

Liste des livrables par bloc de compétences

Cliquer sur les liens pour naviguer vers les livrables.

BC01 - Construction et alimentation d'une infrastructure de gestion de données

Une étude de 1 page décrivant schématiquement l'infrastructure conceptualisée et le code source permettant de construire l'infrastructure.

Lien	Description
Livrable 1	Infrastructure conceptualisée.

Aucun scraper n'a été utilisé dans ce projet. Afin de valider la compétence **C1.3**, vous pouvez consulter mon [ECF1](#) pour une implémentation d'un scraper avec la bibliothèque **Beautiful Soup**.

Spark n'a pas été utilisé dans ce projet. Afin de valider les compétences **C1.2** et **C2.3**, vous pouvez consulter mon [ECF3](#) pour une implémentation python utilisant le SDK d'**Apache Spark**.

BC02 - Analyse exploratoire, descriptive et inférentielle de données

Deux codes sources décrivant l'analyse de chacune des bases de données, incluant la construction de graphiques.

Lien	Description
Livrable 2.1	EDA GuitarSet.
Livrable 2.2	EDA IDMT-SMT-GUITAR.
Livrable 2.3	EDA Dataset frame-wise.

BC03 - Analyse prédictive de données structurées par l'intelligence artificielle

Trois codes sources incluant la conception et l'optimisation de trois algorithmes adaptés à la problématiques ainsi que des recommandations sur les prédictions obtenues.

Lien	Description
Livrable 3.1	Conception et évaluation de 4 modèles : OVR LogisticRegression, OVR LinearSVC, OVR HistGradientBoosting, OVR SGDClassifier. Optimisation du modèle OVR HistGradientBoosting. Etude de l'ajout d'une PCA.

Le projet est intrinsèquement supervisé. Cependant un algorithme non supervisé pourrait avoir plusieurs intérêts, comme l'exploration de la structure des données ou encore la détection des anomalies. J'ai réalisé une réduction de dimensions dans le [livrable 3.1](#). Afin de valider la compétence **C3.3**, vous pouvez consulter le

notebook [C33-analyse_non_supervisee](#) présentant une segmentation client sur le jeu de données *Mall Customers Dataset*.

Une analyse de l'influence des variables n'a pas été menée dans ce projet. Afin de valider la compétence **C3.4**, vous pouvez consulter mon [ECF3](#) pour une analyse de l'influence des variables sur un modèle de détection de churn.

BC04 - Analyse prédictive de données non-structurées par l'intelligence artificielle

Un code source incluant la conception de l'algorithme et les métriques de performances sur des données de validation.

Lien	Description
Livable 4.1	MLP sur dataset frame-wise.
Livable 4.2	CNN + MLP et RCNN sur dataset frame-wise avec context window.

Dans ce projet, les techniques de data augmentation et de transfert learning n'ont pas été utilisées. Afin de valider les compétences **C4.3** et **C4.4**, vous pouvez consulter le notebook [C43C44-data_augmentation_fine_tuning](#) présentant une data augmentation sur le jeu de données *CIFAR-10* et un transfert learning à partir du modèle *MobileNetV3Small*.

BC05 - Industrialisation d'un algorithme d'apprentissage automatique et automatisation des processus de décision

Un code source contenant la création de l'environnement standardisé, le déploiement de l'algorithme et l'application web ainsi qu'un URL vers l'application déployée.

Lien	Description
Livable 5	Déploiement de l'application sur HuggingFace.

BC06 - Direction de projets de gestion de données

Le code source correspond au projet data développé et une soutenance orale de 10 minutes suivie de 5 minutes de questions et éventuellement de 5 minutes d'entretien.

Lien	Description
Livable 6	Support pour la soutenance.