

Veille technologique

GuitarFlow - Projet de transcription audio vers MIDI

1. Table des matières

- 1. Table des matières
- 2. Veille sur les représentations audio
 - 2.1. Comparatif des features audio
 - 2.1.1. STFT (Short-Time Fourier Transform)
 - 2.1.2. Mel Spectrogram
 - 2.1.3. MFCC (Mel-Frequency Cepstral Coefficients)
 - 2.1.4. CQT (Constant-Q Transform) — représentation clé
 - 2.1.5. Chromagram (Chroma / STFT-CQT chroma)
 - 2.2. Matrice de décision
 - 2.3. Décision retenue
- Veille sur les architectures de modélisation
 - Comparatif architectures ML
 - 2.2. Matrice de décision
 - 2.3. Décision retenue

2. Veille sur les représentations audio

2.1. Comparatif des features audio

Critère	STFT	Mel Spectrogram	MFCC	CQT	Chromagram
Domaine	Temps–fréquence	Temps–Mel fréquence	Cepstral (Mel compressé)	Temps–fréquence log (pitch-based)	Temps–pitch class (12 notes)
Axe fréquentiel	Linéaire (Hz)	Log perceptif Mel	Compressé (DCT du Mel)	Logarithmique musical	12 classes chromatiques
Résolution basse fréquence (cordes graves guitare)	Faible	Moyenne	Perte d’info	Très élevée	Moyenne à élevée (selon CQT)
Résolution haute fréquence	Bonne	Moyenne	Très réduite	Bonne	Très réduite (car octave-folding)
Conservation des harmoniques	Oui	Oui	Partielle	Très bonne	Non (fusion par classe de note)

Critère	STFT	Mel Spectrogram	MFCC	CQT	Chromagram
Robustesse bruit	Moyenne	Bonne	Bonne (très compacte)	Bonne	Moyenne
Information temporelle	Excellente	Bonne	Réduite	Excellente	Excellente
Information pitch exacte	Oui	Indirecte	Non	Oui (MIDI-aligned)	Non (classe de pitch seulement)
Adaptation guitare → MIDI	Moyenne	Moyenne	Faible	Très élevée (standard de facto)	Moyenne (utile pour accords)
Séparation notes simultanées (polyphonie)	Bonne	Bonne	Faible	Très bonne	Moyenne (fusion harmonique)
Inversion vers signal audio	Oui	Non (perte phase)	Non	Oui (approximatif)	Non
Usage typique en transcription musicale	Baseline CNN	Feature deep learning	Compression ML classique	Modèle SOTA transcription	Détection accords / tonalité

2.1.1. STFT (Short-Time Fourier Transform)

- Représentation brute temps-fréquence.
- Bonne fidélité physique du signal.
- Limite majeure : résolution uniforme en Hz
 - insuffisante pour distinguer correctement les notes graves (cordes Mi, La de guitare).
- Génère des bins non alignés sur la structure musicale.

Utilisation : baseline CNN, mais sous-optimal pour transcription précise.

2.1.2. Mel Spectrogram

- Compression perceptive (échelle Mel).
- Réduit dimension et bruit.

Limite critique :

- Non linéaire mais non aligné avec les demi-tons musicaux
- Perte de précision pour pitch exact

Bon pour classification globale, moins pour MIDI précis.

2.1.3. MFCC (Mel-Frequency Cepstral Coefficients)

- Compression supplémentaire via DCT du spectre Mel.
- Capture l'enveloppe spectrale (timbre), pas les notes.

Conséquence :

- Très faible utilité directe pour transcription musicale.
- Excellent pour reconnaissance de timbre, pas de hauteur.

Mauvais choix pour guitare → MIDI.

2.1.4. CQT (Constant-Q Transform) — représentation clé

- Axe fréquentiel logarithmique aligné sur les demi-tons.
- Chaque bin correspond directement à une note musicale.

Points forts :

- Très forte résolution dans les basses fréquences (cordes graves guitare).
- Correspondance naturelle avec MIDI (A4 = 440 Hz → mapping direct).
- Très utilisé en transcription automatique moderne.

Limite :

- Coût computationnel plus élevé.

Meilleure représentation globale pour transcription polyphonique guitare → MIDI.

2.1.5. Chromagram (Chroma / STFT-CQT chroma)

- Réduction de toutes les fréquences à 12 classes (C, C#, D... B).
- Ignore les octaves.

Points forts :

- Très bon pour :
 - reconnaissance d'accords
 - tonalité
- Stable musicalement.

Limites critiques :

- Impossible de reconstruire les hauteurs exactes
- Perte totale d'information d'octave → incompatible MIDI précis

Bon pour harmonique global, pas pour transcription note-à-note.

2.2. Matrice de décision

 Matrice de décision features (livrables/gestion_de_projet/veille_technologique.pdf)

2.3. Décision retenue

Pour la tâche spécifique guitare → MIDI, on cherche :

- résolution logarithmique en fréquence,
- séparation des notes simultanées,
- alignement sur la grille MIDI (12-TET),
- conservation des harmoniques.

Hierarchie de pertinence (du meilleur au pire)

- CQT → meilleur choix global (alignement MIDI natif)
- STFT → acceptable mais sous-optimal (résolution non musicale)
- Mel spectrogram → bon pour deep learning général, pas pitch précis
- Chromagram → utile pour accords, pas notes
- MFCC → inutilisable pour transcription musicale fine

Veille sur les architectures de modélisation

Comparatif architectures ML

Architecture	Avantages	Limites
Multiclass + LogisticRegression	Léger	Faible précision
MLP	Simple à implémenter	Peu performant sur séquences
CNN	Bonnes performances fréquentielles	Faible mémoire temporelle
RCNN	Bon compromis temps/fréquence	Plus complexe
Transformer audio	Très performant	Coût GPU élevé

2.2. Matrice de décision

 Matrice de décision features (livrables/gestion_de_projet/veille_technologique.pdf)

2.3. Décision retenue

L'architecture RCNN (Recurrent Convolutional Neural Network) est retenue comme architecture principale.

Le RCNN présente le meilleur compromis entre :

- performances de transcription,
- robustesse polyphonique,
- coût d'inférence,
- simplicité de déploiement.